

안녕하세요, 엔투스솔루션 AI부서 인턴 김은오입니다. 오늘 'AI 및 데이터 기술 활용 방안'에 대한 발표로 여러분께 인사드리게 되었습니다. 이번 발표에서는 AI와 데이터 기술이 더 이상 복잡하거나 적용하기 어려운 기술이 아니라는 점을 다양한 사례를 통해 소개하고, 이를 통해 어떻게 업무 효율성을 높일 수 있는지 함께 생각해 보는 시간을 가지려고 합니다. AI와 데이터 기술은 생각보다 쉽게 시작할 수 있으며, 다양한 분야에서 유용하게 활용될 수 있는 중요한 도구입니다. 이번 발표를 통해 이러한 기술들을 이해하고, 실제 업무에 어떻게 적용할 수 있을지 고민하는 기회가 되었으면 좋겠습니다.

오늘 발표의 흐름을 간단히 설명드리겠습니다. 먼저, 연차 관리 자동화 사례를 통해 AI와 데이터 기술의 기본 개념과 차이점을 살펴보겠습니다. 그 후, 다양한 사례를 통해 엔투스솔루션에 어떻게 적용되었는지 보여드릴 예정입니다. 이러한 사례를 바탕으로 추후 활용 전략을 제시한 뒤, 결론과 Q&A로 발표를 마무리하겠습니다. 간단한 질문이라도 얼마든지 질문해 주시면 감사하겠습니다.

사실, AI와 데이터 기술의 유용성은 다들 잘 알고 계실 것입니다. 하지만 우리는 세 가지 질문을 던질 수 있습니다. '어디에?', '어떻게?', 그리고 '얼마나 유용할까?'라는 질문이죠.

본격적인 설명에 앞서, 간단한 활용 사례를 하나 소개드리겠습니다. 혹시 눈치채신 분이 계실까요? 여기있는 이미지들은 AI를 활용해 만든 것입니다. 다들 한 번쯤 이런 경험이 있으실 겁니다. PPT를 만들기 위해 적절한 이미지를 찾고, 저작권을 확인하고, 이미지를 저장해 넣는 과정에서, 화질이 좋지 않거나 크기가 맞지 않아 다른 이미지를 찾아야 했던 경험 말이죠.

그러나 이제는 방법만 알면 이미지 생성 AI를 활용해 누구나 자연스러운 이미지를 손쉽게 만들 수 있습니다. 더 나아가, 입력한 내용을 바탕으로 발표에 어울리는 PPT 템플릿을 자동으로 작성해주는 AI 기술도 사용할 수 있습니다.

실제로 이 개요 화면도 AI를 이용해 제작했습니다. 제가 스크립트를 작성해 제공하면, AI가 레이아웃을 지정하고 이미지를 생성하여 완성한 것입니다. 매우 간단하고 당연한 활용 사례지만, AI에 익숙하지 않으셨다면 쉽게 지나칠 수 있는 부분이라 간단히 소개해 드렸습니다.

반면 AI 활용은 비교적 익숙하지만, 데이터 기술은 조금 더 생소하신 분들도 있을 것 같습니다. 아마 대부분 데이터베이스 관련 기술을 떠올리셨을 텐데요.

여기서 제가 직접 진행했던 사례를 토대로 설명드리려고 합니다.

혹시 여러분은 팀원들의 연차가 얼마나 남았는지 알고 계신가요? 대부분은 연차 정보를 외우고 다니지 않겠지만, 필요하면 직접 물어보거나 시스템에서 조회하면 알 수 있습니다. 우리는 이렇게 주어진 데이터에서 정답을 찾는 데 익숙합니다. 하지만, 주어진 정보 외의 내용을 파악하려면 직접 계산하거나, 추가 자료를 투입해야 하는 경우가 많습니다.

그런데 팀의 규모가 100명, 200명으로 늘어난다면 어떨까요? 이 방식은 한계에 부딪히게 됩니다. 요즘은 데이터 기술과 AI를 결합해 이러한 문제를 해결하는 경우가 많습니다. AI는 주어진 데이터를 효율적으로 처리하고, 사람은 미래에 필요한 정보를 수집하고 활용하는 데 집중하는 것이죠. 생각의 무게중심이 과거에서 미래로 옮겨가는 것입니다.

데이터 기술은 매우 광범위하지만, 간단히 말해 "어떤 데이터를 어떻게 수집, 관리, 가공, 그리고 활용할 것인가?"에 대한 문제입니다. 이러한 데이터를 어떻게 효율적으로 처리할지, 또한

이를 어떻게 의사결정에 반영할지에 대한 과제도 포함됩니다.

제가 진행했던 실시간 연차 대시보드는 이 데이터 기술의 좋은 예입니다. 다우오피스에서는 연차 현황을 파악할 수 있는 대시보드가 없었고, 제공하는 목록 다운로드 기능도 한정적이었습니다. 이를 해결하기 위해 전자결제 문서를 크롤링하여, 결제 문서가 업데이트되면 연차 현황에 자동으로 반영되는 시스템을 구축했습니다.

스케줄러 기능을 통해 하루에 여러 번 데이터를 자동으로 수집하고, 이러한 변화를 실시간으로 대시보드에 반영했습니다. 또한, 캐싱 기능을 활용해 데이터가 많아지더라도 이전에 계산된 데이터를 저장해두어 빠르게 처리할 수 있도록 하였습니다. 이 기능 덕분에 필터를 적용하거나 그래프를 갱신할 때도 성능 향상이 있었습니다.

실제로 구현된 화면에서는 월별로 몇 명이 연차를 사용하는지, 주로 어떤 요일에 많이 사용하는지, 부서별 연차 사용 패턴 등을 확인할 수 있습니다. 또한 사용자가 원하는 정보에 따라 필터를 적용하고, 필요한 데이터를 시각적으로 분석할 수 있는 상호작용 기능도 제공됩니다. 이를 통해 부서 일정 조율이나 연차 계획을 보다 효율적으로 세울 수 있습니다.

결국 AI와 데이터의 차이는 무엇이나라고 한다면

“팀원들의 남은 연차 정보를 크롤링을 통해 수집해서, 앞으로 남은 기간동안의 기대 자원을 계산해봐야겠다”와 같이 재료를 준비하고 메뉴를 생각하는 것은 데이터 기술의 영역입니다. 반대로 실제로 이러한 데이터를 기반으로 계산하거나 예측하는 등의 실제 요리하는 부분들은 모두 AI가 담당하는 것이죠.

이렇게 AI와 데이터의 차이에 대해 자세히 설명드린 이유는, 엔투솔루션의 AI 활용이 데이터에서 시작되어야 함을 강조하기 위함입니다. 실제로 딥러닝과 같은 고도화된 AI 모델의 활용은 현재 기술적, 환경적 어려움이 있지만, 데이터 기반의 직관적 시각화를 통한 의사 결정 지원에는 큰 도움이 될 것입니다.

특히, 데이터에 대한 탄탄한 기반이 마련되면, 추후 AI 모델을 도입할 때도 더욱 효과적으로 활용할 수 있습니다. 데이터를 체계적으로 수집하고 관리하며, 이를 해석하는 능력을 갖춘다면 AI의 예측과 자동화 기능을 더욱 신뢰할 수 있을 것입니다. 결국 데이터는 AI의 근간이자 필수 자원이며, 현재의 데이터 역량이 미래 AI 활용의 성공 여부를 결정짓는 중요한 요소입니다.

다음은 제가 입사 후 처음으로 진행했던 과제입니다.

서비스를 이용하는 근로자가 현재 위치에서 n 개의 매장을 선택해 근무할 때, 출발지로 다시 돌아오는 가장 빠른 경로를 찾는 문제를 해결하는 과제였습니다. 이는 외판원 문제와 유사한 내용이었지만, 전체 매장 리스트 중에서 n 개를 선택한다는 차이점이 있었습니다. 이를 해결하기 위해 최적의 경로를 찾는 자체 알고리즘을 구현했습니다.

먼저, 매장 정보를 수집하기 위해 네이버 지도에서 이마트, 홈플러스, 롯데마트 등을 검색하고, 주소를 크롤링하여 데이터를 생성했습니다. 화면을 보시면, 자동으로 주소 부분을 클릭해 복사하고 저장하는 과정을 거쳐, 우측에 보이는 형태로 CSV 파일로 저장되었습니다.

프로그램의 전체적인 흐름은 다음과 같습니다. 네이버에서 제공하는 MAP API를 활용해, 이전에 추출된 각 대형마트의 주소를 위경도로 변환한 후, 매장 간 이동에 걸리는 실제 소요 시간을 계산했습니다. 여기서 한 가지 문제가 있었는데, 단순히 거리를 계산하는 것과 달리, 실제 소요 시간을 추출하는 과정에서는 연산이 많이 필요해 시간이 오래 걸렸습니다. 그래서 모든 매장 간 거리를 계산하는 것은 비효율적이라 판단하고, 이를 최적화하기로 했습니다. 최적화를 위해 매장 간 실제 소요 시간을 행렬 형태로 캐싱하여 저장해두고, 이후 필요할 때마다 이 저장된 데이터를 활용하는 방식으로 진행했습니다.

이렇게 하면, 사용자가 위치를 입력하면 가장 가까운 n개의 매장에 대한 실제 소요 시간만 계산합니다. 이후, 저장된 값들의 조합을 활용해 최적의 경로를 도출한 후,

그중 상위 n개의 경로에 대해서만 실제 소요 시간을 다시 검색하는 방식으로 연산 시간을 크게 줄였습니다. 이 과정 덕분에 연산 시간을 1/10 수준으로 낮추면서도, 매번 계산하는 것과 비슷한 정확도를 유지할 수 있었습니다.

찾은 최적 경로들은 웹에서 시각화하여 출력되며, 우측 화면에서 보시는 것처럼 네이버 지도와 경로 최적화 프로그램을 통해 동일한 시간대의 소요 시간을 비교한 결과, 거의 일치하는 것을 확인할 수 있었습니다. 약간의 미세한 차이는 동일한 시간대에 API에서 소요 시간을 추출하는 과정과 네이버 지도에서 결과를 출력하는 시간 차이에서 발생한 것으로 보입니다.

다음으로 진행한 과제는 salesUP 데이터 시각화입니다.

salesUP의 경우 아직 데이터가 충분히 모이지 않았기 때문에, 저는 두 가지 방법을 채택하여 데모 버전을 제작했습니다. 첫 번째 방법은 기존에 존재하는 salesUP과 비슷하거나 연관된 공공 데이터를 수집해 활용하는 것이고, 두 번째는 더미 데이터를 직접 생성하여 시각화하는 것입니다.

먼저, 공공 데이터를 시각화한 자료부터 보여드리겠습니다.

해당 시각화는 서울 행정구역별 사업자 현황 데이터를 활용했습니다. 각 지역별로 등록된 사업자 수에 따라 지도를 진하게 표시하였고, 해당 지역의 사업자 카테고리 분포는 파이차트를 통해 시각화했습니다. 사업자 수가 많은 지역일수록 색이 진하며, 카테고리가 어떻게 분포되어 있는지도 한눈에 확인할 수 있습니다. 비록 이번에는 사업자 관련 데이터를 시각화했지만, 추후에는 특정 브랜드의 매출 분포를 분석하는 방식으로도 활용할 수 있을 것입니다.

다음으로 보여드릴 데이터는 대전광역시 신용카드 매출 분석 데이터(국민은행)를 사용한 시각화입니다.

이 시각화에서는 카테고리별 매출을 색상으로 표현하여, 어떤 지역에서 특정 카테고리의 매출이 높은지를 시각적으로 확인할 수 있습니다. 이를 통해 매출이 높은 지역에 추가 매장을 입점하거나, 매출이 상대적으로 낮은 지역에서는 품목 변경을 고려하는 등의 전략적 결정을 할 수 있습니다. 또한, 특정 지역을 선택하면 해당 지역에서 가장 많이 팔린 카테고리를 바 차트로 보여줍니다. 이를 통해 그 지역에서 어떤 품목을 판매하면 좋을지 간단히 파악할 수 있습

니다.

다음으로 소개드릴 내용은 더미 데이터를 활용한 사례입니다.

더미 데이터를 생성할 때, 저는 크게 세 가지 원칙을 중점적으로 고려하였습니다. 개연성, 상관성, 그리고 우연성입니다. 한마디로 말하자면, 어떻게 하면 데이터에 최대한의 현실성을 부여할 수 있을까에 대한 고민이었습니다. 즉, 현실에서 실제로 기록될 법한 데이터를 만드는 것이 목표였습니다.

조금 더 구체적으로 말씀드리자면, 단순히 데이터를 무작위로 생성하는 것은 현실에서 기록되는 데이터와 매우 다를 수밖에 없습니다. 그렇기 때문에 많은 조건을 부여해줘야 현실과 비슷한 데이터 분포를 얻을 수 있습니다. 예를 들어, 계약 분포를 생각해보면, 실제 데이터는 시간에 따라 고른 분포를 보이는 경우가 많습니다. 하지만 처음 생성한 데이터는 초반 구간 공백이 생기는 등 불균형한 분포가 나타납니다(중간에 있는 이미지처럼). 그래서 다양한 조건을 부여해 우측 이미지처럼 고른 분포를 갖도록 조정했습니다.

이와 같은 문제는 상관성을 설정할 때도 발생합니다. 예를 들어, 저는 근태 점수를 피드백 점수라는 형태로 측정했습니다. 피드백 점수는 파견 횟수가 늘어날수록 증가하도록 설정하고, 피드백 점수와 파견 횟수에 따라 판매량이 증가하도록 만들었습니다. 그러나 이러한 관계를 단순히 설정하면 부자연스러운 데이터가 나오기 때문에, 이를 현실적으로 보이게 하기 위해 다양한 계산식과 분포를 사용했습니다.

또한, 개개인의 적성을 반영하기 위해 직원마다 네 가지 카테고리(예: 신발, 의류 등)에 대한 기준 피드백 점수와 판매량 수치를 부여했습니다. 이렇게 함으로써, 어떤 직원은 신발을 잘 팔고, 다른 직원은 의류를 잘 파는 등, 현실적인 조건을 반영할 수 있었습니다.

이러한 조건들을 추가하여 생성한 데이터는 다음과 같습니다.

날짜 순서에 따라 기록되며, 동일한 직원 ID로 그룹화된 형태입니다. 보시는 것처럼, 직원 001의 근무 기록이 출력되고 있으며, 마치 실제 계약을 맺은 것처럼 계약 시작일과 계약 종료일, 이에 따른 주 3일과 5일 근무를 수행하고 있습니다. 또한, 같은 날 두 개 이상의 매장에서 근무할 경우, 매장 간 이동 시간을 고려해 1시간의 공백을 부여하는 등 현실적인 조건을 반영했습니다.

이렇게 생성된 더미 데이터를 바탕으로 다양한 시각화 분석을 진행했습니다.

먼저, 왼쪽 위 화면에서는 근태 및 근무 기록을 시각화한 내용을 확인할 수 있습니다. 파란 점과 선은 피드백 점수와 파견 횟수별 매출량을 나타냅니다. 오른쪽으로 갈수록 피드백 점수와 파견 횟수가 높다는 것을 의미하며, 이 값들이 높을수록 매출도 높아지는 상관관계를 확인할 수 있습니다. 이 상관관계를 명확하게 보여주기 위해 직선 추세선과 곡선 추세선을 활용했습니다.

현재는 더미 데이터를 사용했기 때문에 상관관계가 명확하게 나타나지만, 실제 데이터에서는 더 복잡한 패턴이 나타날 수 있습니다. 예를 들어, 피드백 점수가 0점 이하에서는 판매량에 유의미한 영향을 미치지 않지만, 그 이상의 점수는 별다른 영향을 미치지 않을 수 있습니다. 이런

경우, 피드백 점수 목표치를 0점으로 설정하고 교육 방향을 잡는 것이 더 합리적인 결정이 될 수 있습니다.

다음으로, 월별 근무 인원과 대기 중인 인원, 근무일과 비근무일의 비율을 바 차트로 시각화 하였고, 일별 데이터는 이동 평균을 적용하여 추이를 확인했습니다.

또한, 파견 빈도에 따른 피드백 점수의 변화를 분석하기 위해 히트맵 시각화를 진행했습니다. 파견 빈도가 늘어날수록 피드백 점수가 상승하는 경향을 확인할 수 있습니다.

이 외에도 매장과 날짜를 선택하여, 각 매장에 근무 중인 직원과 해당 직원의 시간표를 파이차트로 시각화하였으며, 기본적인 판매량 변화 시각화도 진행해주었습니다.

이 외에도, 매장과 날짜를 선택하여 각 매장에 근무 중인 직원과 그들의 시간표를 파이차트로 시각화했습니다. 또한, 기본적인 판매량 변화도 시각화하였습니다. 여기서 한 가지 응용된 부분은, 매출액이나 판매량은 계약 수와 밀접한 관계를 가지기 때문에, 계약이 많을수록 매출이 높게 나타나는 경향이 있습니다. 이를 반영하여, 근무당 판매량 변화도 확인할 수 있도록 계산식을 적용해 시각화했습니다. 이를 통해 직원들의 숙련도 변화를 확인할 수 있습니다. 예를 들어, 파란선으로 표시된 24년에는 근무당 평균 매출액이 낮은 반면, 초록 선으로 표시된 26년에는 더 높은 매출을 기록한 것을 볼 수 있습니다.

우측 아래에는 각 직원에 대한 시각화도 포함되어 있습니다. 예를 들어, 주간 근무 시간이 많아질수록 피드백 점수가 어떻게 변하는지를 시각화한 결과를 보면, 근무 시간이 많아질수록 평균 피드백 점수는 증가하지만, 최대치는 낮아지는 현상이 나타났습니다. 또한, 계약직과 정규직 여부에 따른 피드백 점수, 카테고리별 매출을 직원별로 분석하여, 어떤 직원이 특정 카테고리의 품목을 가장 잘 판매하는지도 시각화했습니다. 더불어, 급여에 따른 피드백 점수, 매장 거리와 피드백 점수의 관계도 시각화하였으며, 년도별 급여 변화도 분석했습니다.

모든 시각화는 체크박스과 범례를 클릭해 상호작용할 수 있도록 설정되어, 사용자가 원하는 정보에 쉽게 접근할 수 있도록 구현되었습니다.

마지막으로, 유의미한 데이터가 많이 모이면 다음과 같은 예측을 진행할 수 있습니다.

저는 Prophet 모델을 활용하여 하루 평균 매출액을 기반으로 향후 매출액을 예측하는 그래프를 생성했습니다. 여기서 주목할 점은 예측 범위인데, 이 모델은 예측 범위를 벗어난 값을 이상치로 간주합니다. 이를 통해 매출액에 급격한 변화가 발생하면 보다 빠르게 이상치를 감지할 수 있다는 장점이 있습니다.

오른쪽 그래프에서는 현재 매출액의 추세가 어떻게 변화하고 있는지를 보여줍니다. 또한, 연도별 주기성을 파악할 수 있는데, 어느 달에 판매량이 높게 나타나는지 확인할 수 있습니다. 더 나아가, 요일별 매출 데이터도 시각화하여 어떤 요일에 판매가 많이 이루어지는지도 분석할 수 있습니다.

이처럼 데이터를 시각화하는 것은 의사결정을 더 직관적으로 만들며, 이는 경영에 유의미한 도움을 줍니다. 이러한 시각화만으로도 굳이 AI가 결정을 내리지 않더라도, 충분히 큰 효과를 기대할 수 있을 것으로 보입니다.

다음으로 설명드릴 과제를 위해 하나의 상황을 가정해 보겠습니다.

새로 입사한 A씨가 회사 규정에 대해 알아보려면 어떻게 해야 할까요? 보통은 선임에게 물어보거나 직접 찾아보는 방법이 있겠죠. 하지만 이러한 방법들은 효율적이지 않습니다. 선택의 여지가 없었기 때문에 그동안 이런 방식이 사용된 것이죠. 그런데 이런 상상을 해보겠습니다.

만약 GPT에게 물어서 회사 규정을 쉽게 알 수 있다면? A씨와 선임 모두 업무 효율성이 크게 향상될 것입니다. 하지만 현재 GPT는 일반적인 질문에는 답변을 잘하더라도, 회사의 특수한 규정에 대해서는 정확한 답을 제공하지 못합니다.

물론, 규정에 관한 질문은 입사하는 인원이 많지 않아서 큰 문제는 아닐 수 있습니다. 하지만 다른 경우는 어떨까요? 저는 실제로 송파세무서 민원봉사실에서 근무한 적이 있는데, 제가 받는 전화의 90%는 전화 연결 문의였습니다. 사람들이 어떤 업무를 처리하려고 할 때, 어느 부서로 연결해야 하는지 묻는 단순한 질문이었습니다. 하루에 수백 통의 전화를 처리하다 보면 목도 아프고, 때로는 악성 민원에 시달려 정신적으로도 지칠 수 있습니다.

만약 이러한 단순한 업무를 AI가 대신 처리해 줄 수 있다면 어떨까요? 회사는 단순 업무에 투입되는 인력을 줄이고, 더 미래지향적인 업무에 인원을 투자할 수 있을 것입니다. 미래 업무에 인원을 투자한 회사와 단순 업무에 인력을 소모한 회사. 10년 뒤 모습은 어떻게 달라질까요?

이런 환경을 구축하려면 먼저 파인튜닝에 대해 알아볼 필요가 있습니다. 혹시 ChatGPT를 사용해보신 분이 계신가요? 아마도 생각보다 많은 분들이 사용해보셨을 것 같습니다. 말씀드린 것처럼 ChatGPT는 일반적인 질문에 대해서는 잘 처리하지만, 특수한 데이터에 대해서는 답변을 제공하지 못하는 경우가 많습니다.

그러면 우리는 이런 질문을 할 수 있습니다. "회사 전반적인 내용을 안내해줄 GPT는 없을까?" 실제로 많은 기업들은 이미 파인튜닝을 활용해 이러한 맞춤형 챗봇을 구현하고 있습니다.

지금 보시는 내용은 파인튜닝에서 주로 사용되는 방법 중 하나인 RAG 방식입니다. RAG는 Retrieval Augmented Generation의 줄임말로, 간단히 설명하자면 생성 모델이 외부 검색 시스템을 통해 실시간으로 최신 정보를 검색하고, 이를 바탕으로 답변을 생성하는 방식입니다. 쉽게 말해, 누군가가 엔투스솔루션에 대해 물어봤을 때, 엔투스솔루션에 관한 사전이 미리 주어지면 그 사전에서 정보를 찾아 답변해주는 시스템이라고 이해하시면 됩니다.

이러한 방식은 다른 파인튜닝 방식에 비해 비교적 간단하게 구현할 수 있으며, 모델 드리프트(모델 배포 후 성능 저하)나 망각(새로운 정보로 인해 이전 정보를 잊는 현상)에서 자유롭다는 장점이 있습니다. 하지만 학습에 필요한 스크립트를 직접 작성해야 하고, 응답 시간이 길어질 수 있다는 단점이 존재합니다. 그럼에도 불구하고, 파인튜닝은 상당한 기술적 자원과 환경적 자원을 요구하기 때문에, 비교적 효율적인 RAG 방식을 사용했습니다.

제가 진행한 것은 LLaMA 3.1이라는 오픈소스 기반의 거대 언어 모델을 RAG 방식으로 파인튜닝한 것입니다.

혹시 LLaMA 모델이 생소하신 분도 있을 텐데요, LLaMA는 페이스북에서 만든 AI 모델로, 오픈소스라는 강점이 있습니다. 성능 면에서도 ChatGPT와 비슷하거나 더 뛰어난 성능을 보일 때도 있습니다. 하지만 LLaMA 3.1 대용량 모델을 활용하려면 최소 7천만 원 이상의 고성능 컴퓨터가 필요하기 때문에, 이번에는 현실적인 8B 모델을 사용했습니다.

LLaMA의 또 다른 장점은 로컬 환경에서 작업을 수행할 수 있어, 엔투스솔루션의 민감한 정보를 외부로 노출시키지 않고도 맞춤형 언어 모델을 운영할 수 있다는 점입니다.

대형 언어 모델을 파인튜닝하여 맞춤형 챗봇을 만드는 과정을 요약하자면, LLaMA 3.1 모델을 선택해 질문-답변 형식의 데이터셋을 구축한 뒤, 이를 기반으로 파인튜닝하여 챗봇을 구현하는 방식입니다.

이 과정을 통해 완성된 엔투챗봇의 모습은 다음과 같습니다. 실제로 몇 가지 질문을 해보았으며, 우측 상단에 사전 설정된 정보를 바탕으로 답변을 제공하는 것을 확인할 수 있습니다. 또한, 입력된 데이터와 다소 다른 표현으로 물어봐도 원활하게 답변할 수 있었습니다.

다만, 현재 모델은 시연을 목적으로 제작된 것이기에 실제 업무에 활용하기에는 성능적 한계가 있습니다. 추후 외부 GPU 자원을 활용하거나 자체 워크스테이션을 구축해 학습 및 서비스를 진행한다면 더 높은 성능을 기대할 수 있습니다.

이렇게 구현된 챗봇은 CSS 매개변수를 사용해 사용자 정의 스타일을 추가하거나, HTML과 자바스크립트를 수정해 기존 인터페이스를 확장할 수 있습니다. 또한, Gradio는 웹 환경에서 동작하므로, Chart.js나 D3.js 같은 외부 자바스크립트 라이브러리와 연동할 수 있다는 점도 큰 장점입니다.

지금까지 제가 입사 후 진행했던 과제들에 대해 말씀드렸습니다. 아직 입사한 지 한 달 정도 밖에 되지 않아 다른 프로젝트에 대한 지식은 부족하지만, 제가 다뤘던 사례들이 AI 활용에 대한 유익한 아이디어를 제공드릴 수 있었다면 좋겠습니다.

저 또한 앞으로 AI 기술을 어떻게 더 잘 활용할 수 있을지에 대해 나름대로 활용 전략을 생각해 보았습니다.

첫째, 데이터 파이프라인 구축입니다.

이전에 진행했던 연차 자동 관리 시스템, 경로 탐색, salesUP 시각화처럼 데이터를 자동으로 수집, 처리, 시각화하는 과정들을 자동화하는 것은, 다양한 솔루션을 제시할 수 있는 원동력이 될 것입니다.

둘째, 엔투솔루션이 최신 AI 기술의 흐름에 발맞추는 전략을 수립하는 것입니다.

AI는 지금보다 더 빠른 속도로 발전할 것이며, 이를 놓치지 않기 위해 지속적인 관심과 대응이 필요합니다. 불과 1년 전만 해도 이미지 생성 AI가 주목받았지만, 이제는 음성, 영상 생성형 AI가 새로운 트렌드로 떠오르고 있습니다. 저는 2024년 4분기쯤에 AI 비서가 큰 화두가 될 것이라고 예상하며, 이러한 발전에 발맞춰 다양한 활용 방법을 모색하고 적용할 예정입니다.

셋째, 일반 업무에서 AI를 활용해 직원들의 생산성을 높이는 것입니다.

AI는 인간의 업무를 완전히 대체하는 것이 아니라, 현재 사용되는 자원을 효율화하여 미래에 더 큰 가치를 창출할 수 있도록 도와주는 역할을 합니다. 예를 들어, 소프트웨어 테스트 직군에서는 AI를 활용해 테스트케이스 작성이나 오류 수정을 자동화하고, 직원들은 더 중요한 디자인 리뷰나 요구사항 정리에 집중할 수 있습니다. 실제로 네이버 클라우드팀에서도 마이크로소프트 코파일럿 같은 코딩 어시스턴트를 사용해 생산성을 크게 향상시켰다는 사례가 있습니다.

하지만 이를 위해서는 AI를 직접 경험하고 이해하는 과정이 필요합니다.

따라서 기회가 된다면, 생산성 향상에 도움이 될 수 있는 다양한 AI 툴과 사용 방법에 대해서도 간단히 공유드릴 수 있을 것이라 생각합니다.

오늘 발표를 통해 AI와 데이터 기술이 엔투스루션에서 다양하게 활용될 수 있으며, 업무 효율성을 크게 향상시킬 수 있는 강력한 수단임을 설명드렸습니다. 특히, 데이터 기반 관리와 AI의 예측 및 자동화 기능을 통해 더 스마트하고 효과적인 의사결정이 가능하다는 점을 확인할 수 있었습니다.

ChatGPT와 같은 생성형 AI의 등장은 LLM을 포함한 다양한 AI 기술에 대한 관심을 급격히 증가시켰습니다. 하지만 많은 사람과 기업이 이를 어떻게 효과적으로 활용할지에 대해 여전히 막막해하는 상황입니다. 저는 앞으로 다양한 AI 솔루션을 공부하고 활용하여, 엔투스루션이 AI 관련 컨설팅까지 수행할 수 있도록 징검다리 역할을 수행하고 싶습니다.

이를 통해 엔투스루션은 AI와 데이터 기술을 도입하고 발전시켜, 경쟁력을 유지하고 지속적으로 성장할 수 있는 기반을 마련할 수 있을 것입니다. 앞으로도 지속적인 학습과 혁신을 통해 AI 기술을 효과적으로 활용하여, 회사의 비전과 목표를 실현해 나가겠습니다.

발표 후 Q&A 시간에는 여러분과 더 구체적인 논의를 나누며, AI와 데이터 기술의 실질적인 도입 방안에 대해 이야기할 수 있으면 좋겠습니다. 많은 관심과 참여 부탁드립니다. 오늘 발표를 들어주셔서 감사합니다.

가우시안 분포 = 정규 분포라고도 하며 기댓값, 최빈값, 중앙값이 모두 같은 분포를 의미합니다. 여기서는 역 가우시안 형태를 통해 중심에 대한 가중치를 낮추고, 양 끝부분에 동일한 가중치를 부드럽게 설정하기 위해 사용해주었습니다.

베타 분포 알파는 양의 방향이므로 파견 횟수에 따른 경험치를 통해 가중치를 부여하고, 베타는 음의 방향이므로 거리에 따른 패널티를 통해 가중치를 부여해주었습니다.

-1.6부터 1.4라는 애매한 값은 초기 피드백 기준치가 -0.3인점을 고려하여 설정하였으며, 스케일링을 통해 -1부터 1 사이의 값으로 조절해 주었습니다

시그모이드 함수를 사용하여 파견횟수가 늘어날수록 매출액에 미치는 영향을 줄어들게 설정하였습니다. 또한 단순히 제공하는 것이 아닌, 최대 최소치의 변화를 부여하여 해당 범위 안에서 끊임없이 난수를 통해 결과가 출력되므로, 파견횟수가 높더라도 매출이 낮게 나타나는 현상을 구현하였습니다

챗봇의 경우 말씀드린 것처럼 질문과 답변 형식으로 된 스크립트를 학습하기 때문에 질문과 답변 형식으로 구현 가능한 내용만 학습 가능합니다. 전달받은 매뉴얼의 경우 질문과 답변 형식으로 구현하기에 어려움이 있어, 이번 과제에서는 보류하였습니다

파인튜닝은 좀 더 넓은 분야의 전문성을 강화하는 작업에 가깝다고 이해하시면 되겠습니다. 예를 들어 chatgpt를 의료 기록 분석을 위한 모델로 파인튜닝한다면, 일단 모델보다 의료분야에 더 정밀한 결과를 제공할 수 있게 됩니다.

데이터파이프라인에 대해 설명드리기 위해, 예전에 진행했던 프로젝트 하나를 말씀드려보자

면, 해당 프로젝트는 이상탐지를 위해 데이터파이프라인을 구축하는 내용이었습니다. 실시간으로 수집되는, 혹은 수집된 내용을 임포트해주면, 이상치를 찾아 시각화해주는 내용이었습니다. 이처럼 사용자입장에서는 자세한 과정에 대해 알 필요없이 단순히 내용을 임포트하고 출력되는 결과를 바로 받을 수 있게 하는 일련의 과정을 구축하는 것을 데이터 파이프라인이라고 할 수 있습니다.

예전에 AI 스피커라고 해서 지니나 클로바같은 것들이 잠깐 유행했던 적이 있는데요. 사실 한계가 명확했다고 생각합니다. 반면 이번에 발표된 제미나이의 경우 단순히 말을 알아듣는 수준을 넘어 사용자의 의도를 파악할 수 있다고 합니다. 양방향 소통에 더욱 가까워졌다고 할 수 있습니다. 예를들어 아빠에게 지난번 다툼에 대해 사과하는 내용의 메일을 보내줘 라고 말하는 것만으로 구체화된 내용의 메일을 보낼 수 있게 되는 겁니다. 혹은 사진을 촬영한 뒤, 어떤 색의 가구가 어울릴까? 하는 등의 질문도 답변할 수 있게 되는 거죠.